

QTrail——基于稀疏奖励强化学习的自适应量子线路映射优化方案

一、总体技术路线与方案设计

量子线路映射问题的核心是**初始映射 (Initial Mapping)**：将逻辑量子比特分配到物理量子比特上，使得后续执行双量子比特门时需要插入的SWAP门数量最少。我们将此问题建模为组合优化中的**二次分配问题 (QAP)**——逻辑量子比特之间的交互关系构成一个程序图，物理硬件的连接关系构成一个耦合图，目标是找到一个双射映射，使得程序图中所有边的交互强度与其在耦合图上对应物理位置间距离的总加权和最小。

QAP是经典的NP-hard组合优化问题。对于传统运筹学方法（如精确求解器、分支定界等），即使问题规模 modest（如50个量子比特），求解时间也可能长达数小时甚至数天，无法满足量子编译对效率的要求。启发式方法（如SABRE）虽然速度快，但其代价函数依赖人工设计，难以自动适应不同电路类型和硬件特性，容易陷入次优解。

因此，本方案参考CO-MAP的RL+后处理框架，总体流程分为四个阶段：特征编码、GNN嵌入、RL策略解码、后处理优化。计划在三个维度上进行扩展：采用Graph Transformer增强逻辑线路特征表示；将归一化后的硬件校准数据融入RL决策实现噪声感知；通过多起点自适应局部搜索改进后处理设计。

为什么选择强化学习？ 强化学习的核心优势在于能够通过与环境的大量交互，自动学习到针对不同输入模式的最优决策策略，而无需人工设计启发式规则。具体而言，我们将初始映射建模为一个**顺序决策过程**：从空映射开始，每一步选择一个逻辑量子比特并将其分配到一个物理位置上，直到所有量子比特都被分配完毕。这种"逐步构造解"的方式天然适合序列决策框架。与此同时，一旦RL策略训练完成，推理时只需一次前向传播即可得到映射结果，速度普遍快于传统优化方法。

为什么需要后处理？ RL策略学到的是面向通用情况的决策模式，但在具体实例的局部细节上可能存在次优选择。后处理相当于在RL输出的高质量解的邻域内进行精细微调，以极低的计算代价修复这些局部缺陷。实验表明，后处理能够带来50%以上的额外性能提升，是将"好的RL解"转化为"优秀的最终解"的关键环节。

在RL训练过程中，本方案采用**稀疏奖励策略**——不在每一步放置后给即时奖励，而是等到所有量子比特都放置完成后，一次性计算全局距离加权和作为奖励。之所以这样设计，是因为单个量子比特的放置对最终SWAP数量的影响是高度非局部的：一个当前看似合理的局部决策，可能在后续迫使其他量子比特绕道，导致大量额外SWAP。只有看到完整的分配结果，才能准确评估某个放置决策的真正价值。这种稀疏奖励虽然增加了训练难度，但有效避免了短视的贪婪行为，使策略学会从全局角度规划映射方案。

这种设计自然地确立了RL与后处理之间的**分工协作关系**：RL负责在宏观上把握"大方向"——将交互密切的量子比特群放置到相近的物理区域，构建出全局合理的映射骨架；后处理则在此基础上进行局部微调——通过交换个别量子比特的位置，修复RL解在局部细节上的次优之处。两者各司其职：RL解决"放在哪个区域"的战略问题，后处理解决"微调具体位置"的战术问题。

二、GNN线路整体特征学习

问题：量子线路的程序图和硬件的耦合图都需要编码为低维向量表示，供RL策略使用。如何设计一个能够充分捕获图结构信息的编码器？

为什么GNN是合适的选择？ 量子线路和硬件拓扑天然具有图结构。传统的手工特征（如节点度数、PageRank、门密度等）需要领域专家设计，且难以捕获图中复杂的模式。图神经网络（GNN）通过消息传递机制自动学习节点嵌入，能够直接从原始图结构中提取对决策有用的特征，减少人工设计特征的局限性。

为什么选用Graph Transformer而非基础GNN？ CO-MAP采用的基础GATConv仅聚合局部邻居信息（通常1-2跳），难以捕获量子线路中的长程依赖关系。实际上，量子线路中相隔较远但逻辑上紧密关联的量子比特对（如量子纠缠中的校验比特）对映射质量有重要影响。Graph Transformer通过全局自注意力机制，使每个节点能够直接关注图中任意其他节点，从而捕获这种长程依赖。此外，量子线路天然具有层次化结构——局部门操作组成块，块再构成完整算法——Graph Transformer的多头注意力机制能够自动提取这种多尺度特征，无需人工设计层次化特征工程。

模块优点：更强的表示能力使RL策略能识别更复杂的线路模式，做出更精准的映射决策；端到端学习减少人工特征工程，提升对新类型线路的泛化性。

三、噪声感知RL决策

问题：现有方法大多仅优化拓扑距离，忽略了真实量子硬件中不同量子比特的相干时间、门错误率存在显著差异这一事实。一个拓扑上稍差但将关键操作放在高保真度区域的映射，实际执行效果可能远优于纯拓扑最优解。如何在RL决策中融入硬件噪声信息？

为什么将校准数据作为节点特征而非重训练模型？ 若针对每种设备的特定校准值单独训练模型，则每次硬件校准变化后都需要重新训练，这在实际中不可行。我们将校准数据（T1/T2相干时间、单/双量子比特门错误率、读出错误率）作为物理量子比特的节点特征输入GNN，并采用**设备级min-max归一化**处理：对每台设备上的校准值单独归一化，使模型学习"相对质量"概念而非绝对数值。归一化后的特征表示每个量子比特相对于该设备上其他量子比特的质量等级，这样同一训练好的模型可通用于同拓扑结构下的不同设备，无需重新训练。

为什么需要噪声加权距离？ 传统QAP目标函数中，距离矩阵仅反映拓扑最短路径。引入噪声感知后，路径上门保真度越低，有效距离越大——即"坏的路径看起来更远"。RL策略在最小化距离加权与时，自然会倾向于将高交互的逻辑量子比特对分配到高保真度的物理路径上，从而实现拓扑优化与噪声规避的联合决策。

模块优点：同一模型适配不同噪声状态的同拓扑设备；噪声感知使映射结果在实际设备上的保真度显著提升。

四、后处理优化

问题：RL策略输出的是基于学习到的通用模式构造的解，但在具体实例上可能不是局部最优。如何在增加太多计算开销的前提下进一步提升解质量？

为什么后处理有效？ RL策略学到的解通常已经落在某个"好解的吸引域"内，与最优解的距离不远。后处理通过在这个邻域内进行局部搜索，能够以很小的计算代价找到更优解。评估一个候选映射的代价只需查距离矩阵，无需重新运行神经网络，因此后处理的每一步都非常快。

为什么改进为多起点自适应搜索？ CO-MAP的后处理采用单起点随机搜索，容易陷入局部最优且探索不充分。我们的改进有两方面：一是**多起点**——通过RL策略的采样解码（而非贪心解码）生成多个不同的候选解作为搜索起点，扩大探索范围；二是**自适应邻域**——初期使用大范围交换操作跳出局部最优，后期转为小范围精细搜索，平衡探索与利用。评估函数也采用噪声感知代价，确保搜索方向与实际执行保真度一致。

模块优点：多起点搜索扩大了解空间的探索范围，自适应邻域操作平衡了全局探索与局部精化，后处理后的映射质量显著优于单一RL解。

五、预期成果

表 1 预期成果

成果类型	具体内容
算法成果	完整的自适应噪声感知量子线路映射系统
评测成果	在MQTBench和Queko基准测试集上的全面评测
实验成果	在国内本源悟空或夸父量子计算平台上进行真机验证

六、研究计划

表 2 研究进度安排（10周）

任务	W1	W2	W3	W4	W5	W6	W7	W8	W9	W10
CO-MAP基线复现										
GNN改进										
噪声感知IRL模块										
后处理优化										
模块集成与评测										
真机实验验证										
报告撰写与修改										
关键里程碑	基线验证				模块完成				报告定稿	