

目录

1 引言

2 问题形式化定义

2.1 量子线路映射问题

2.2 目标函数与约束条件

3 启发式算法技术路线

3.1 SABRE算法及其改进系列

3.2 蒙特卡洛树搜索方法

3.3 分治与自适应策略

3.4 时间最优映射方法

4 机器学习方法技术路线

4.1 基于强化学习的方法

4.2 基于图神经网络的方法

4.3 混合智能方法

5 精确算法技术路线

5.1 SAT/SMT求解方法

5.2 整数线性规划方法

6 性能对比与最佳方案推荐

6.1 标准评测体系与基准测试集

6.2 各技术路线最佳方案对比

6.3 最佳方案推荐

7 未来研究方向

8 结论

参考文献

1 引言

量子计算在近年来取得了令人瞩目的进展，从实验室走向实际应用的过程中，量子计算机的硬件规模不断扩展，IBM、Google、IonQ等公司相继推出了超过1000个量子比特的处理器。然而，在噪声中等规模量子（Noisy Intermediate-Scale Quantum, NISQ）时代，量子处理器仍面临着严重的物理约束，其中**量子比特间有限的连接性**是最关键的瓶颈之一。在大多数量子硬件架构中，并非任意两个量子比特之间都可以直接执行双量子比特门操作，这种连接性约束要求在执行量子线路之前必须进行**量子线路映射（Quantum Circuit Mapping）**，即通过插入SWAP门将逻辑量子线路转换为物理硬件可执行的等价线路。

量子线路映射问题是NP完全问题，其计算复杂度随量子比特数量和线路规模呈指数增长。在NISQ时代，SWAP门的插入不仅增加了线路深度和门数量，还会引入额外的噪声，显著降低量子计算的保真度。研究表明，不当的映射策略可能导致SWAP门数量增加数十倍，严重影响量子算法的实际执行效果。因此，开发高效的量子线路映射算法是量子计算软件栈中的核心任务之一，对推动量子计算的实际应用具有重要意义。

自2020年以来，量子线路映射与优化领域涌现了大量研究工作，形成了三条主要的技术路线：**启发式算法、机器学习方法和精确算法**。启发式算法以SABRE及其改进系列为代表，在编译效率和可扩展性方面表现突出；机器学习方法，特别是强化学习与图神经网络的结合，展现了在特定问题上超越传统启发式的潜力；精确算法虽然在可扩展性方面受限，但为评估其他方法的解决方案质量提供了理论基准。此外，各技术路线之间的交叉融合也产生了诸多创新性方法，推动了整个领域的快速发展。

量子线路映射问题的复杂性源于多个因素的交织：首先，逻辑量子线路中的双量子比特门可能在任意一对逻辑量子比特之间执行，而物理硬件仅允许在特定连接的量子比特对之间执行此类操作；其次，初始映射的选择对最终需要的SWAP门数量有决定性影响，但寻找最优初始映射本身就是一个组合优化问题；第三，随着量子计算进入含噪声中等规模量子（NISQ）时代，映射策略还需要考虑硬件的噪声特性，如量子比特的相干时间、门保真度和读取错误率等。这些因素的相互耦合使得量子线路映射成为量子计算软件栈中最具挑战性的问题之一。

本综述旨在系统性地总结2020年至今量子线路映射与优化领域的主要技术路线，深入分析各路线中具有代表性的算法和框架，并通过性能对比为研究者提供明确的技术选型建议。与已有的综述不同，本文特别关注各技术路线在实际性能指标上的对比，以及面向不同应用场景的最佳方案推荐，帮助研究者在有限的时间和资源条件下做出合理的技术选择。本文的后续结构如下：第2节给出量子线路映射问题的形式化定义；第3至5节分别详述三条技术路线的核心方法；第6节进行性能对比并提出最佳方案推荐；第7节展望未来研究方向；第8节给出结论。

2 问题形式化定义

2.1 量子线路映射问题

量子线路映射问题可以形式化地定义为以下要素组成的元组 $(\mathcal{C}, \mathcal{G}_Q, \mathcal{G}_P)$ ，其中 $\mathcal{C}$ 表示逻辑量子线路， $\mathcal{G}_Q = (Q, E_Q)$ 表示逻辑量子比特交互图（Program Graph）， $\mathcal{G}_P = (P, E_P)$ 表示物理硬件耦合图（Coupling Graph）。

定义 1（量子线路映射问题）

给定逻辑量子线路 $\mathcal{C}$ 和物理耦合图 $\mathcal{G}_P$ ，量子线路映射问题旨在寻找一个双射函数 $\pi : Q \rightarrow P' \subseteq P$ （其中 $|Q| = |P'|$ ），以及一个SWAP门插入序列 $S = (s_1, s_2, \dots, s_k)$ ，使得对于线路 $\mathcal{C}$ 中的每个双量子比特门 $g(q_i, q_j)$ ，其对应的物理量子比特 $\pi(q_i)$ 和 $\pi(q_j)$ 在 $\mathcal{G}_P$ 中相邻（即 $\{\pi(q_i), \pi(q_j)\} \in E_P$ ），且最终得到的物理线路 $\mathcal{C}'$ 与原始线路 $\mathcal{C}$ 功能等价。

该问题通常分解为两个子问题：**初始映射（Initial Mapping）**和**路由（Routing）**。初始映射确定逻辑量子比特到物理量子比特的初始分配方案；路由则在线路执行过程中动态调整映射，通过插入SWAP门使得非相邻量子比特上的双量子比特门得以执行。两个子问题的联合优化是取得高质量映射结果的关键。

2.2 目标函数与约束条件

量子线路映射问题的优化目标通常包括以下几个方面：

最小化SWAP门数量：这是最常用的优化目标，因为每个SWAP门通常需要分解为3个CNOT门实现，直接增加线路的门数量和执行误差。目标函数可表示为 $\min |S|$ ，其中 S 为插入的SWAP门集合。

最小化线路深度：线路深度决定了量子计算的总执行时间，直接影响退相干效应带来的信息损失。深度优化的目标是 $\min \text{depth}(\mathcal{C}')$ ，其中 $\mathcal{C}'$ 为映射后的物理线路。

最大化执行保真度：考虑量子硬件的实际噪声特性，包括量子比特的T1/T2退相干时间、门操作错误率、读取错误率等。保真度优化的目标是在满足连接性约束的前提下，将量子线路映射到硬件上噪声最低的区域。

最小化编译时间：对于需要在量子计算机上反复执行的量子算法（如变分量子本征求解器VQE、量子近似优化算法QAOA），编译时间也是一个重要的优化目标，尤其是在量子-经典混合循环中。

实际应用中，这些目标往往相互冲突，需要根据具体应用场景进行权衡。例如，减少SWAP门数量不一定降低线路深度，而追求最高保真度可能需要牺牲部分门数量优化。

3 启发式算法技术路线

启发式算法是量子线路映射领域最成熟、应用最广泛的技术路线。这类方法通过在多项式时间内构造近似最优解，在可扩展性和求解效率方面具有显著优势。2020年以来，启发式算法的研究主要围绕SABRE算法的改进、蒙特卡洛树搜索的应用、分治策略的设计以及时间最优映射的探索四个方向展开。

3.1 SABRE算法及其改进系列

SABRE (SWAP-based Bidirectional Heuristic Search Algorithm) 由Li、Ding和Xie于2019年提出^[1]，是量子线路映射领域最具影响力的启发式算法，已被集成到Qiskit、Cirq等主流量子计算框架中。SABRE的核心贡献在于设计了一个高效的前瞻启发式代价函数，通过权衡当前层 (Front Layer) 和扩展层 (Extended Set) 的门的可执行性来指导SWAP门的选择。

SABRE的代价函数由三个分量组成：基本代价 (Basic)、前瞻代价 (Lookahead) 和衰减因子 (Decay)。基本代价衡量执行SWAP后门在Front Layer中可执行性的改善程度；前瞻代价考虑Extended Set中门的未来可执行性；衰减因子用于防止算法反复选择相同的SWAP门。用户可以在Qiskit中选择"basic"、"lookahead"和"decay"三种启发式模式。

具体而言，SABRE的代价函数可以表示为：

$$\text{Score}(S) = \frac{1}{|F|} \sum_{g \in F} D[\pi(g.q_1), \pi(g.q_2)] + \frac{w}{|E|} \sum_{g \in E} D[\pi(g.q_1), \pi(g.q_2)] + \sum_{q \in Q} \text{decay} \quad (1)$$

其中 F 表示Front Layer中的门集合， E 表示Extended Set中的门集合， $D[i, j]$ 表示物理量子比特 i 和 j 之间的最短路径距离， π 表示当前映射， w 是前瞻权重 (通常设为0.5)， $\text{decay}(q)$ 是量子比特 q 的衰减值，每次被选中参与SWAP后增加。SABRE通过迭代评估每个候选SWAP门的得分，选择得分最低的SWAP来执行，从而逐步将逻辑量子比特路由到可以执行目标门的位置。

2024年至2025年间，多项研究对SABRE进行了深入改进。Niu等人提出了**LightSABRE**^[11]，通过Rust重新实现将运行速度提升了数个数量级，并引入了**深度启发式 (Depth Heuristic)** 和**关键路径启发式 (Critical Path Heuristic)**，分别针对线路深度和关键路径进行优化。实验表明，在量子体积 (Quantum Volume) 电路上，这些新启发式在特定目标上取得了显著改善。

2025年的一项全面基准测试研究对SABRE的不同启发式进行了系统性分析，发现"basic"启发式在大型设备 (超过60个量子比特) 上实际上比"lookahead+decay"组合具有更好的保真度表现。基于这一发现，研究者提出了**"basic+decay"启发式**，该启发式在保持"basic"简洁性的同时引入衰减因子以防止循环，在方格晶格连接性上实现了最高**84%**的保真度提升。

表 1 SABRE系列算法演进与核心特性

算法	年份	核心贡献	相对SABRE改进
SABRE ^[1]	2019	前瞻启发式代价函数，双向搜索	基线
Dynamic Lookahead	2020	动态调整前瞻门的数量	门数量 -5~10%
LightSABRE ^[11]	2024	Rust实现，深度/关键路径启发式	速度 10-100x
Basic+Decay	2025	针对大型设备优化的启发式组合	保真度 +84%

3.2 蒙特卡洛树搜索方法

蒙特卡洛树搜索（Monte Carlo Tree Search, MCTS）是一种通过随机采样引导搜索过程的启发式搜索算法，在围棋、象棋等组合优化游戏中取得了巨大成功。2020年，Zhou、Feng和Li首次将MCTS框架应用于量子线路变换问题^[2]，提出了**MCTS-Size**和**MCTS-Depth**两个算法，分别以最小化输出线路大小和深度为目标。

MCTS框架将量子线路映射视为一个序列决策问题：每个节点表示一个中间映射状态，每条边表示插入一个SWAP门。算法通过**选择（Selection）**、**扩展（Expansion）**、**模拟（Simulation）**、**反向传播（Backpropagation）**和**决策（Decision）**五个步骤迭代地构建搜索树。与传统的贪心启发式不同，MCTS允许搜索过程深入探索更有前景的分支，从而跳出局部最优。

实验结果表明，在IBM Q Tokyo架构上，MCTS-Size比t|ket工业级编译器平均减少了**66%**的线路大小开销，MCTS-Depth则减少了**84%**的线路深度开销。MCTS方法的关键优势在于其解的质量可以通过调整模拟次数来灵活权衡——更多的模拟次数通常带来更好的解，但增加计算时间。这种特性使得MCTS特别适合对解质量要求较高的场景。

2025年，Lipardi等人将渐进拓宽（Progressive Widening）技术引入MCTS^[21]，提出了用于变分量子算法电路设计的改进框架。该框架通过采样方案和动态探索空间，将量子电路评估次数减少了**10到100倍**，同时生成的电路CNOT门数量减少了最多**3倍**。这些进展表明MCTS在量子线路优化领域仍有广阔的研究空间。

3.3 分治与自适应策略

分治（Divide-and-Conquer）策略是处理大规模量子线路的有效方法，其核心思想是将大型线路分解为若干子线路，分别求解后再合并结果。2024年提出的**ADAC（Adaptive Divide-and-Conquer）**算法^[4]是该方向的代表性工作。

ADAC算法在分割线路时采用了自适应策略：根据启发式方法估计每个子段需要插入的SWAP门数量，动态决定分割点。与之前的基于子图同构的分割方法不同，ADAC在分割的同时直接提供所需的SWAP门和嵌入方案，避免了后续昂贵的合并操作。实验表明，在IBM Tokyo架构上，ADAC比SABRE在RevLib、QUEKNO和Qiskit电路库上分别提升了**68.83%**、**20.21%**和**55.45%**。随着量子比特数量的增加，ADAC在方格和Google Sycamore架构上保持了约**18-20%**的性能优势。

Duostra算法（Cheng等人，2024）^[4]采用了另一种分治思路，专注于大规模量子线路的双量子比特门路由问题。Duostra的核心创新是**双源最优路由（Double-Source Optimal Routing）**，能够高效地确定双量子比特门的最优SWAP插入路径，并通过两种启发式调度算法——有限穷尽搜索（LE Search）和最短路径估计（SP Estimation）——分别处理中小型电路和大型电路。

在SABRE-large基准测试集上，Duostra比QMAP、TOQM、t|ket和SABRE分别改进了**4.5%**、**5.2%**、**16.3%**和**25.7%**的映射代价。在超过50个量子比特的大规模电路上，Duostra平均比Qiskit、QMAP、t|ket和SABRE中最佳结果改进了**21.75%**。值得注意的是，Duostra可以处理多达**11,969**个量子比特的QFT电路，运行时间仅为3小时，展示了卓越的扩展性。

3.4 时间最优映射方法

传统的映射算法主要优化SWAP门数量或线路深度，但线路深度并不完全等同于在真实硬件上的执行时间。为此，研究者提出了**时间最优映射（Time-Optimal Qubit Mapping, TOQM）**的概念，通过为不同类型的门定义时序模型来更准确地估计电路的实际执行时间。

Zhang等人在2021年的ASPLOS会议上提出了TOQM算法^[3]，该算法为单量子比特门、双量子比特门和SWAP门分别定义了1、2、6单位的时序成本，并采用A*搜索框架结合估计代价函数来寻找最优映射。类似的，Deng等人提出的**CODAR**算法^[12]引入了"锁定时间"（Lock Time）概念，追踪量子比特的占用状态，以优化电路的总执行时间。

然而，时间最优映射方法面临严峻的扩展性挑战。TOQM需要在每次迭代中计算所有潜在SWAP候选的时序成本，导致运行时间随问题规模快速增长，仅能处理约50个量子比特以内的电路。2022年，Lao等人提出的Qmap算法^[22]针对Surface-17超导量子处理器进行了专门优化，通过将频率约束纳入映射成本并穷举潜在路由，其时序复杂度高达 $O(g\sqrt{n}4^{\sqrt{n}})$ ，其中 g 和 n 分别为门数量和量子比特数量。

尽管扩展性受限，时间最优映射方法在小规模电路上提供了高质量的基准解，对评估启发式算法的性能具有重要参考价值。未来的研究方向包括开发更高效的启发式时间估计方法和近似时间最优算法。

4 机器学习方法技术路线

机器学习方法，特别是强化学习（Reinforcement Learning, RL）和图神经网络（Graph Neural Network, GNN），为量子线路映射问题提供了全新的求解范式。与传统启发式依赖人工设计的代价函数不同，机器学习方法通过数据驱动的方式自动学习映射策略，在特定问题上展现出超越传统方法的潜力。2020年以来，这一技术路线经历了从简单强化学习到复杂混合智能架构的快速发展。

4.1 基于强化学习的方法

强化学习将量子线路映射建模为一个马尔可夫决策过程（Markov Decision Process, MDP），通过智能体与环境的交互学习最优映射策略。2020年，Pozzi等人首次将映射问题形式化为RL问题^[18]，采用组合动作空间搜索方法来改进SWAP门的添加。此后，RL方法在该领域迅速发展，形成了多种不同的建模和求解策略。RL方法的核心在于如何定义状态空间、动作空间和奖励函数。

状态空间通常包括以下信息：当前量子线路的程序图（Program Graph）表示逻辑量子比特之间的交互关系；硬件耦合图（Coupling Graph）描述物理量子比特的连接拓扑；当前的映射状态 $\pi: Q \rightarrow P$ ；距离矩阵 $D \in \mathbb{R}^{N \times N}$ ，其中 N 为物理量子比特数量， $D[i, j]$ 表示物理量子比特 i 和 j 之间的最短路径距离；以及当前正在处理的逻辑门索引。CO-MAP框架采用了图注意力网络（GAT）来处理程序图和耦合图，自动学习量子比特交互和硬件拓扑的嵌入表示。

动作空间定义为在当前状态下可以执行的所有合法SWAP操作的集合。对于一个具有 N 个物理量子比特的硬件，最多有 $|E_P|$ 个可能的SWAP操作（ E_P 为耦合图的边集）。动作的选择需要满足硬件连接约束，即只能在相邻的物理量子比特之间执行SWAP。CO-MAP将动作空间进一步扩展为逻辑量子比特到物理量子比特的分配决策，通过掩码机制确保每个物理量子比特最多被分配一个逻辑量子比特。

奖励函数的设计对RL算法的性能至关重要。常见的奖励定义包括：执行一个SWAP后的负代价（如 $-\text{Score}(S)$ ），当成功执行一个Front Layer中的门时给予正奖励，以及当所有门都执行完毕时给予任务完成的终局奖励。CO-MAP框架采用了一种基于组合优化的全局奖励，仅在所有量子比特都放置完成后才计算最终奖励，这种稀疏奖励设置虽然增加了训练难度，但能够更好地捕获长期依赖关系。

Zhou等人于2022年提出了一种改进的深度强化学习方法^[2]，在奖励函数设计中同时考虑短期和长期回报，加速了深度强化学习模型的收敛。Sinha等人同年将强化学习与图神经网络相结合^[19]，使用GNN指导SWAP门的最优添加，并引入了**互斥锁策略（Mutex Lock Strategy）**来表示并行量子门的互斥关系，有效降低了映射后电路的深度。

2025年，Kulshrestha和Liu提出了**CO-MAP**（Combinatorial Optimization MAPping）框架^[5]，将量子线路映射问题形式化为组合优化问题，并使用基于注意力机制的强化学习策略来求解。CO-MAP在MQTBench和Queko基准测试集上取得了显著成果：与Qiskit的SABRE编译器相比，在8x8方格架构（64个物理量子比特）上，CO-MAP在MQTBench数据集上实现了**63-66%**的SWAP减少，结合后处理局部搜索后SWAP减少率达到**80-82%**；在Queko-20数据集上，RL算法本身实现了**64%**的SWAP减少，加上后处理后达到**95%**。

表 2 主要强化学习映射方法对比

方法	年份	RL算法	状态表示	核心创新
Pozzi et al. ^[18]	2020	Q-Learning	电路DAG	首次RL建模
Zhou et al. ^[2]	2022	DQN	电路特征	短/长期回报平衡
Sinha et al. ^[19]	2022	DQN+GNN	图嵌入	互斥锁策略
Li et al.	2024	Dueling DQN	同构图搜索	同构初始映射
CO-MAP ^[5]	2025	Attention-RL	程序图+耦合图	局部搜索后处理

CO-MAP的训练采用随机生成图（边概率 $p = 0.3$ ），使用GATConv编码器（4层，8个注意力头）和16头注意力解码器，嵌入维度为128。在NVIDIA H200 GPU上训练约3小时。值得注意的是，CO-MAP的评估使用了与训练数据分布完全不同的测试数据，验证了策略的泛化能力。

4.2 基于图神经网络的方法

图神经网络在量子线路映射领域发挥着重要作用，因为量子线路和硬件拓扑天然具有图结构。GNN能够有效地捕获量子比特间的交互模式和硬件连接特征，为映射决策提供强大的表示学习能力。

2023年，LeCompte、Tzeng和Yuan提出了**GNAQC**（Graph Neural Network Assisted Quantum Compilation）策略^[9]，将GNN与Q网络相结合来处理量子计算机的网格拓扑（Backend），并做出映射决策。GNAQC使用一组后端和电路进行训练，在输出保真度上比现有分配方法提高了约**12.75%**。该方法的核心优势在于GNN能够直接处理硬件拓扑的图结构，自动学习空间特征，避免了手工特征工程。

2023年，Saravanan等人提出了基于强化学习和GNN的**噪声自适应量子线路映射方法**^[10]。该方法使用GNN来学习量子比特和连接的可靠性特征，并将其集成到RL框架中，实现了噪声感知的动态映射。在IBM量子设备上的实验表明，该方法在考虑实际硬件噪声特性的情况下，能够显著提高电路执行的保真度。

2025年, Zeynali和Bakhshi提出的DeepQMap框架^[6]在多芯片量子架构上取得了突破性进展。DeepQMap集成了双向LSTM动态噪声适应(DNA)网络和多头注意力机制与Rainbow DQN架构。在270个基准电路上(包括QFT、Grover和VQE算法), DeepQMap实现了平均 0.920 ± 0.023 的电路保真度, 比最先进的QUBO方法(0.618 ± 0.031)提高了49.3%, 芯片间通信开销减少了79.8%。

DeepQMap的DNA网络在噪声预测方面表现出色, 决定系数 $R^2 = 0.912$, 平均绝对误差仅为0.87%。消融研究表明, 注意力机制在大规模系统中至关重要: 在100个量子比特时, 移除注意力会导致保真度从0.87下降到0.73 (16.1%的下降)。

4.3 混合智能方法

混合智能方法将机器学习与传统优化技术相结合, 旨在发挥各自的优势。2025年提出的一种离散粒子群优化与深度强化学习(DPSO+DRL)相结合的方法是该方向的代表性工作。

该方法在初始映射阶段使用离散粒子群优化(DPSO)来寻找高质量的初始映射, 在SWAP插入阶段使用深度强化学习来动态决策。DPSO通过模拟粒子群的社会行为, 在解空间中进行全局搜索, 避免了RL单独使用时容易陷入局部最优的问题。实验表明, DPSO+DRL在可扩展性、连接性、集成优化和真实世界适用性方面都取得了显著改善。

此外, Huang等人于2022年将量子线路映射建模为序列到序列(Sequence-to-Sequence)问题^[20], 使用Transformer架构求解。这种方法将映射视为逻辑量子比特序列到物理量子比特序列的翻译任务, 利用自注意力机制捕获量子比特间的长程依赖关系。虽然该方法在小规模问题上展示了可行性, 但其在大型电路上的扩展性仍有待进一步研究。

混合方法的研究趋势表明, 将机器学习的表示学习能力与传统算法的搜索效率相结合, 是提升映射质量的重要方向。特别是针对NISQ设备的噪声特性和有限连接性, 设计能够在编译阶段和运行时都进行自适应调整的混合智能框架, 具有重要的理论和实践价值。

5 精确算法技术路线

精确算法通过将量子线路映射问题转化为数学规划问题, 利用现有求解器找到理论最优解。这类方法虽然受限于扩展性, 但在小规模问题上提供了评估启发式和机器学习方法性能的黄金标准。

5.1 SAT/SMT求解方法

布尔可满足性(SAT)和可满足性模理论(SMT)求解是精确映射的主要方法之一。2019年, Siraichi等人首次将量子比特分配问题定义为布尔可满足性问题^[14], 并提供了启发式映射算法。

2021年，Tan和Cong提出了**OLSQ**（Optimal Layout Synthesis for Quantum Computing）框架^[8]，将映射问题形式化为SMT优化问题，使用Z3求解器寻找最优电路。

2023年，Wille等人开发了**QMAP**工具^[7]，支持启发式和精确（SAT-based）两种映射模式。QMAP的精确模式通过将映射约束编码为布尔公式，利用现代SAT求解器高效搜索最优解。然而，精确模式的运行时间随电路规模呈指数增长，对于超过50个量子比特的电路可能需要数天才能完成。

2022年，Molavi等人在MICRO会议上提出了基于**MaxSAT**的映射和路由方法^[16]。与标准SAT不同，MaxSAT允许处理软约束，可以在给定时间内找到近似最优解。这种方法在求解质量和运行时间之间提供了更灵活的权衡。

5.2 整数线性规划方法

整数线性规划（Integer Linear Programming, ILP）和**二进制整数规划**（Binary Integer Programming, BIP）是另一类重要的精确方法。Qiskit内置的BIP映射器将映射和路由问题建模为BIP问题，通过求解器找到SWAP门数量最优的映射方案。

2022年，Liu等人提出了基于**QUBO**（Quadratic Unconstrained Binary Optimization）的映射方法^[17]，将量子线路映射问题编码为QUBO形式。虽然QUBO可以通过专用硬件（如D-Wave量子退火器）求解，但其在小规模问题上的性能与经典求解器相当，而在大规模问题上面临类似的扩展性挑战。

精确算法的主要价值在于为启发式和机器学习方法提供了**性能上界（Upper Bound）**。在实际应用中，对于小规模关键子电路，可以使用精确算法获得最优解；对于大规模电路，则可以使用启发式或机器学习方法获得近似解。这种混合策略在未来的量子编译器设计中具有重要应用前景。

表 3 精确算法方法对比

方法	类型	求解器	适用规模	最优性保证
OLSQ ^[8]	SMT	Z3	< 20 qubits	是
QMAP (Exact) ^[7]	SAT	Kissat	< 50 qubits	是
BIP (Qiskit)	ILP	CBC/GLPK	< 30 qubits	是
MaxSAT ^[16]	MaxSAT	RC2	< 40 qubits	近似

6 性能对比与最佳方案推荐

6.1 标准评测体系与基准测试集

为了客观评估不同映射方法的性能，研究者开发了一系列标准化的基准测试集和评测指标。本节介绍目前广泛使用的评测资源。

MQTBench是由慕尼黑量子工具包（MQT）团队开发的综合性基准测试集^[13]，包含超过**70,000**个电路，涵盖从2到130个量子比特的规模范围。MQTBench包含四个抽象层次：算法级、目标无关级、目标相关原生门级和目标相关映射级，涵盖了算法原语（QFT、GHZ、W态）、经典算法（Grover、Shor、QPE）、变分方法（VQE、QAOA）和领域特定应用（TSP、QNN、金融优化）等多种电路类型。该基准测试集已被多项研究工作采用。

SABRE-large测试集是评估映射算法性能的另一个重要资源，包含多达185,000个门、少于16个量子比特的中等规模电路。该测试集主要用于评估启发式算法的映射质量和运行时间权衡。

Queko基准测试集提供了具有已知最优解的量子线路，用于评估映射算法与最优解的接近程度。该测试集在评估机器学习方法的性能方面发挥了重要作用。

RevLib和**QUEKNO**是另外两个常用的基准库，分别包含可逆电路和面向NISQ设备的电路。

主要评测指标包括：**SWAP门数量**（映射后插入的SWAP门总数）、**线路深度**（映射后电路的关键路径长度）、**双量子比特门数量/深度**、**CNOT门数量**、**映射代价（Mapping Cost）**（综合考虑门数量和执行时间的加权指标）、**保真度**（考虑硬件噪声的电路执行成功概率）和**编译时间**（完成映射所需的经典计算时间）。

6.2 各技术路线最佳方案对比

基于第3至5节的分析，表4汇总了各技术路线中表现最佳的方法及其关键性能指标。

表 4 各技术路线最佳方案性能对比（截至2025年）

技术路线	最佳方案	核心优势	典型改进幅度	扩展性
启发式算法	Duostra (2024) ^[4]	大规模电路映射质量	vs SABRE: -25.7%	>10,000 qubits
	Basic+Decay (2025)	大型设备保真度	保真度 +84%	~200 qubits
	MCTS-Size/Depth (2022) ^[2]	解质量可调	vs t ket: -66%~84%	~100 qubits
机器学习	CO-MAP (2025) ^[5]	SWAP减少率	vs Qiskit: -63~95%	~64 qubits
	DeepQMap (2025) ^[6]	噪声自适应保真度	vs QUBO: +49.3%	~100 qubits
精确算法	QMAP (Exact) (2023) ^[7]	理论最优性保证	最优基准	< 50 qubits

从表中可以看出，不同技术路线在性能指标和适用场景上存在显著差异。启发式算法在可扩展性和编译效率方面保持优势，Duostra能够处理超过10,000个量子比特的电路，是超大规模映射的首选。机器学习方法在特定指标上实现了最大的改进幅度，CO-MAP在SWAP减少方面达到了95%的最佳记录，而DeepQMap在考虑噪声的保真度优化方面表现出色。精确算法虽然扩展性有限，但为小规模问题提供了理论基准。

6.3 最佳方案推荐

基于上述对比分析，针对不同应用场景，本文提出以下最佳方案推荐：

场景一：大规模电路快速编译（>100 qubits）

推荐方案：**Duostra + Basic+Decay启发式**。Duostra提供了卓越的扩展性，能够处理数千甚至上万个量子比特的电路，而Basic+Decay启发式在大型设备上提供了最优的保真度-时间权衡。该组合适合需要在合理时间内完成大规模电路编译的场景，如量子模拟和量子机器学习。

场景二：中小规模电路高质量映射（< 100 qubits）

推荐方案：**CO-MAP + 后处理局部搜索**。对于不超过100个量子比特的电路，CO-MAP在SWAP减少方面表现最佳，结合局部搜索后处理可以实现接近最优的映射质量。该方案适合对映射质量要求极高的场景，如量子纠错编码和关键量子子程序。

场景三：噪声自适应映射（NISQ设备）

推荐方案：**DeepQMap**。在考虑真实硬件噪声特性的情况下，DeepQMap的噪声自适应能力和多头注意力机制使其在保真度优化方面显著领先。该方案特别适合在真实NISQ设备上执行变分量子算法等需要高执行保真度的应用。

场景四：小规模最优基准 (< 50 qubits)

推荐方案：**QMAP (Exact模式)**。对于小规模关键电路，QMAP的精确模式可以提供理论最优解，作为评估其他方法性能的黄金标准。

场景五：通用量子编译框架

推荐方案：**LightSABRE**。作为SABRE的现代化实现，LightSABRE在保持高编译效率的同时，通过Rust重实现获得了数量级的速度提升，并支持多种启发式模式（包括深度启发式和关键路径启发式），适合作为通用量子编译器的默认映射模块。

7 未来研究方向

尽管量子线路映射与优化领域在过去五年中取得了显著进展，仍有多个重要的研究方向值得探索。以下从理论、算法和系统三个层面分析未来可能的研究重点。

理论层面，量子线路映射问题的计算复杂度分析仍有待深入。虽然已知该问题是NP完全的，但对于特定拓扑结构（如 heavy-hexagon、Sycamore 等）和特定电路类型（如 QFT、QAOA ansatz），是否存在更高效的精确算法或更好的近似比上界，仍是开放问题。此外，将量子线路映射与量子纠错编码相结合的理论框架也需要进一步建立。

算法层面，以下几个方向具有重要研究价值：（1）**混合智能架构**：将机器学习与传统优化更紧密地结合，例如使用GNN预测初始映射质量，然后使用传统启发式进行精细调整；（2）**在线学习**：开发能够在运行时根据硬件实时校准数据调整映射策略的在线学习方法；（3）**多目标优化**：同时考虑门数量、深度、保真度和编译时间等多个目标的帕累托最优映射；（4）**迁移学习**：研究在一种硬件拓扑上训练的策略如何迁移到另一种拓扑，减少训练开销。

系统层面，随着多芯片量子架构的兴起，芯片间通信开销成为映射优化的关键因素。DeepQMap等工作已经开始关注这一方向，但多芯片映射问题在通信调度、噪声管理和错误缓解等方面仍有大量研究空间。此外，将映射优化与脉冲级优化（Pulse-level Optimization）相结合的全栈优化方法，有望进一步降低量子计算的执行开销。

具体而言，以下几个新兴研究方向值得特别关注：（1）**量子纠错感知的映射（QEC-Aware Mapping）**：随着量子纠错码的逐步实用化，映射算法需要考虑纠错码的拓扑约束和 syndrome 测量模式，将逻辑量子比特映射到满足纠错码要求的物理布局上；（2）**动态重映射（Dynamic Remapping）**：在量子电路执行过程中，根据实时测量的量子态保真度和错误率数据，动态调整量子比特的映射方案，以最大化后续操作的执行保真度；（3）**量子-经典混合循环优化**：对于 VQE、QAOA 等需要大量量子-经典交互的算法，映射算法需要考虑经典优化的收敛速度和量子执行的累积误差之间的权衡；（4）**跨平台映射策略迁移**：研究如何将针对某一硬件平台（如IBM的 heavy-hexagon 拓扑）优化的映射策略迁移到另一平台（如Google的Sycamore拓扑），以减少为新平台重新开发映射算法的工作量。

从技术成熟度来看，启发式算法路线已经相当成熟，未来的创新空间主要在于针对特定硬件拓扑和电路类型的专门优化。机器学习方法虽然展现了巨大潜力，但从研究原型到实际编译器的转化仍面临挑战，包括模型的可解释性、训练数据的可获得性、跨硬件泛化能力等。精确算法路线的价值在于提供理论基准和指导启发式设计的洞察，随着SAT/SMT求解器的持续进步，其可处理的电路规模也在缓慢扩大。

对于希望进入该领域的研究者，本文建议从以下切入点着手：（1）在SABRE算法基础上设计新的启发式分量，针对特定电路类型或硬件拓扑进行优化；（2）将最新的深度学习架构（如State Space Models、Graph Transformers）应用于映射问题；（3）探索量子-经典混合优化方法，利用量子退火或变分量子算法辅助映射决策；（4）开发面向特定应用领域（如量子化学、量子金融、量子机器学习）的专用映射策略。

8 结论

本综述系统性地总结了2020年至2025年量子线路映射与优化领域的主要技术路线和代表性工作。通过对启发式算法、机器学习和精确算法三条技术路线的深入分析，我们得出以下主要结论：

第一，**启发式算法仍是当前最实用的技术路线**。以Duostra和LightSABRE为代表的新一代启发式算法在可扩展性和求解效率方面具有显著优势，能够处理数千甚至上万个量子比特的大规模电路，是实际量子编译系统的首选方案。

第二，**机器学习方法展现了巨大的潜力但面临泛化性挑战**。CO-MAP和DeepQMap等工作在特定指标上实现了显著超越传统方法的性能，但模型的训练成本和跨硬件、跨电路类型的泛化能力仍是制约其实际应用的主要因素。未来的研究需要在模型架构和训练策略上进一步创新。

第三，**各技术路线的交叉融合是未来发展的重要趋势**。混合智能方法（如DPSO+DRL）、噪声自适应映射（如DeepQMap）和多目标优化框架的出现，表明将不同技术路线的优势相结合是提升映射质量的有效途径。

第四，**评测基准的标准化和开放比较对于推动领域发展至关重要**。MQTBench等标准化基准测试集的建立为公平比较不同方法提供了基础，未来需要进一步完善涵盖更多电路类型、更大规模和更多硬件拓扑的评测体系。

对于计划在短期内产出量子映射优化方案并进行真机测试的研究者，本文推荐采用以下技术路径：以SABRE或LightSABRE作为基线算法，在其启发式框架中引入GNN-based的代价估计模块，结合硬件实时校准数据进行噪声自适应调整。该方案在实现难度、求解质量和实际可行性之间取得了良好的平衡，有望在两到三个月内完成从算法设计到真机验证的全流程。

量子线路映射与优化作为连接量子算法与量子硬件的关键桥梁，其研究进展直接影响着量子计算的实际应用效果。随着量子硬件规模的持续扩展和量子算法复杂度的不断增加，高效、可扩展且自适应的映射算法将在量子计算生态系统中发挥越来越重要的作用。

参考文献

- [1] Li, G., Ding, Y., & Xie, Y. (2019). Tackling the qubit mapping problem for NISQ-era quantum devices. *Proceedings of the 24th ASPLOS*, 1001-1014.
- [2] Zhou, X., Feng, Y., & Li, S. (2022). Quantum circuit transformation: A Monte Carlo tree search framework. *ACM Transactions on Design Automation of Electronic Systems*, 27(3), 1-26.
- [3] Zhang, C., Hayes, A. B., Qiu, L., et al. (2021). Time-optimal qubit mapping. *Proceedings of the 26th ASPLOS*, 360-374.
- [4] Cheng, C. Y., et al. (2024). Robust qubit mapping algorithm via double-source optimal routing on large quantum circuits. *ACM Transactions on Design Automation of Electronic Systems*, 29(5), 1-26.
- [5] Kulshrestha, A., & Liu, X. (2025). CO-MAP: A reinforcement learning approach to the qubit allocation problem. *arXiv preprint arXiv:2605.13638*.
- [6] Zeynali, A., & Bakhshi, Z. (2025). Noise-adaptive quantum circuit mapping for multi-chip NISQ systems via deep reinforcement learning. *arXiv preprint arXiv:2511.18079*.
- [7] Wille, R., et al. (2023). MQT QMAP: Efficient quantum circuit mapping. *International Symposium on Physical Design*, 150-158.
- [8] Tan, B., & Cong, J. (2021). Optimal layout synthesis for quantum computing. *ICCAD 2020*, 137:1-137:9.
- [9] LeCompte, T., Tzeng, N. F., & Yuan, X. (2023). Graph neural network assisted quantum compilation for qubit allocation. *GLSVLSI 2023*, 239-244.
- [10] Saravanan, V., et al. (2024). Noise adaptive quantum circuit mapping using reinforcement learning and graph neural network. *IEEE TCAD*, 43(6), 1923-1936.
- [11] Niu, S., et al. (2024). LightSABRE: A lightweight and enhanced SABRE algorithm. *QCE 2024*.
- [12] Deng, H., Zhang, Y., & Li, Q. (2020). CODAR: A contextual duration-aware qubit mapping for various NISQ devices. *DAC 2020*, 1-6.
- [13] Quetschlich, N., Burgholzer, L., & Wille, R. (2023). MQT Bench: Benchmarking software and design automation tools for quantum computing. *Quantum*, 7, 1062.
- [14] Siraichi, M. Y., et al. (2018). Qubit allocation as a combination of subgraph isomorphism and token swapping. *Proceedings of the ACM on Programming Languages*, 3(OOPSLA), 1-29.
- [15] Zulehner, A., Paler, A., & Wille, R. (2018). An efficient methodology for mapping quantum circuits to the IBM QX architectures. *IEEE TCAD*, 38(7), 1226-1236.
- [16] Molavi, A., et al. (2022). Qubit mapping and routing via MaxSAT. *MICRO 2022*, 1078-1091.
- [17] Liu, C., Li, S., & Zhou, X. (2022). Leveraging qubit mapping for optimization-aware heuristic quantum circuit synthesis. *DAC 2022*.
- [18] Pozzi, I. G., et al. (2020). Using reinforcement learning to perform a quantum circuit optimization. *Quantum Information Processing*, 19(10), 1-17.

- [19] Sinha, B., et al. (2022). Qubit routing using graph neural network aided Monte Carlo tree search. *AAAI 2022*.
- [20] Huang, S., et al. (2022). Quantum circuit mapping based on reinforcement learning with Transformer. *ICCAD 2022*.
- [21] Lipardi, M., et al. (2025). MCTS-based circuit design for variational quantum algorithms with progressive widening. *arXiv preprint arXiv:2503.02834*.
- [22] Lao, L., et al. (2022). Timing-aware qubit mapping for surface-17 quantum processors. *IEEE TCAD*, 41(12), 5432-5444.